

Sveučilište Jurja Dobrile u Puli  
Fakultet Informatike u Puli  
Robotika

## **Optimizacija Arhitekture Neuronske Mreže za Predikciju Izlazne Snage Elektrane Pomoću Genetskog Algoritma i Diferencijalne Evolucije**

*Leo Radočaj (303094823), Lorena Pavlić (24205305)*

Mentor: *doc. dr. sc. Ivan Lorencin*

### **Sažetak**

U ovom radu razvijen je model dubokog učenja za predikciju električne snage kombinirane plinske elektrane (Combined Cycle Power Plant – CCGT) na temelju četiriju ulaznih značajki: ambijentalna temperatura, ambijentalni tlak, relativna vlažnost zraka i vakuum ispušnih plinova. Arhitektura višeslojne perceptronske mreže (MLP) optimizirana je korištenjem dvaju populacijskih optimizacijskih algoritama: Genetskog algoritma (GA) i Diferencijalne evolucije (DE). Optimizacija je provedena nad brojem skrivenih slojeva, brojem neurona po sloju te stopom učenja. Model je vrednovan pomoću metrika srednje kvadratne pogreške (MSE), korijenске srednje kvadratne pogreške (RMSE) i koeficijenta determinacije ( $R^2$ ). Dobiveni rezultati ukazuju na visoku točnost modela, s  $R^2$  vrijednošću iznad 0.94, što potvrđuje učinkovitost predložene metode i njenu potencijalnu primjenjivost u energetske sustavima.

### **1. Uvod**

Predikcija proizvodnje električne energije predstavlja ključnu komponentu optimizacije rada elektroenergetskih sustava, posebice u okruženjima koja podliježu varijacijama okolišnih parametara. Kombinirane plinske elektrane često su izložene utjecajima vanjskih uvjeta, kao što su temperatura zraka, tlak i vlažnost, koji značajno utječu na učinkovitost sustava. Tradicionalni pristupi temeljeni na linearnim modelima često nisu sposobni adekvatno uhvatiti nelinearne odnose među varijablama.

U ovom istraživanju predložena je primjena modela dubokog učenja, točnije višeslojne perceptronske mreže (en. Multilayer Perceptron ili MLP), za modeliranje i predikciju izlazne električne snage elektrane. Nadalje, hiperparametri modela, uključujući broj slojeva, broj neurona u slojevima te stopu učenja, optimizirani su korištenjem Genetskog algoritma (GA) i Diferencijalne evolucije (DE), dvaju robusnih metaheurističkih algoritama. Pristup se nadovezuje na prethodna istraživanja, uključujući rad Lorencina i suradnika, koji su demonstrirali učinkovitost sličnih metoda u području pametnih energetske sustava.

## **2. Korišteni skup podataka**

Skup podataka korišten u ovom radu preuzet je s UCI Machine Learning repozitorija pod nazivom *Combined Cycle Power Plant Data Set*. Podaci uključuju 9568 uzoraka mjerenja iz realnih uvjeta rada kombinirane elektrane, a svako mjerenje sadrži sljedeće varijable: ambijentalna temperatura (AT), vakuum ispušnih plinova (V), ambijentalni tlak (AP), relativna vlažnost (RH) te izlazna električna snaga (PE) izražena u megavatima (MW), koja se koristi kao ciljane varijable.

S obzirom na to da podaci ne sadrže prazne vrijednosti niti ekstremne iznimke, mogu se neposredno koristiti za treniranje modela. Prije primjene neuronske mreže, sve ulazne značajke normalizirane su pomoću standardne skale radi osiguravanja numeričke stabilnosti modela.

## **3. Metodologija**

### **3.1 Predobrada podataka**

Cjelokupni skup podataka podijeljen je u dva dijela: 80% podataka koristi se za treniranje modela, dok se preostalih 20% koristi za testiranje. Ulazne značajke skalirane su metodom standardizacije, čime su prevedene na distribuciju sa srednjom vrijednosti nula i standardnom devijacijom jedan. Ova transformacija ključna je za pravilan rad neuronskih mreža jer osigurava da sve značajke imaju ujednačen doprinos pri optimizaciji.

### **3.2 Vizualna analiza podataka**

Korelacijska analiza provedena je pomoću Pearsonove metode i prikazana u obliku toplinske mape (heatmap). Rezultati pokazuju vrlo jaku negativnu korelaciju između ambijentalne temperature (AT) i izlazne snage (PE), s koeficijentom od -0.95. Također je uočena značajna negativna korelacija između vakuuma (V) i izlazne snage, s koeficijentom -0.87. Ambijentalni tlak (AP) pokazuje umjerenu pozitivnu korelaciju (0.52), dok relativna vlažnost (RH) ima slabiju negativnu korelaciju (-0.39).

Dodatno, izrađeni su raspršeni dijagrami koji ilustriraju odnose između pojedinih ulaznih značajki i ciljane varijable. Uočavaju se jasno izraženi linearni i nelinearni obrasci koji potvrđuju opravdanost primjene neuronskih mreža s nelinearnim aktivacijskim funkcijama.

### 3.3 Definicija arhitekture neuronske mreže

Model višeslojne perceptronske mreže (MLP) implementiran je koristeći Keras API. Ulazni sloj odgovara broju značajki (četiri), dok se broj skrivenih slojeva i broj neurona po sloju dinamički mijenjaju ovisno o optimizacijskom algoritmu. Korištene aktivacijske funkcije uključuju LeakyReLU, tanh i selu, koje su odabrane radi bolje nelinearne aproksimacije složenih odnosa. Izlazni sloj sadrži jedan neuron bez aktivacije, prilagođen za regresijski zadatak.

```
def create_mlp(n_hidden, neuron_list, learning_rate):
    model = keras.Sequential()
    model.add(layers.Input(shape=(X_train.shape[1],)))

    activations = [
        LeakyReLU(alpha=0.1), # 1st
        LeakyReLU(alpha=0.1), # 2nd
        "tanh",                # 3rd
        "selu",                 # 4th
        LeakyReLU(alpha=0.1)   # 5th (optional)
    ]
```

### 3.4 Optimizacija hiperparametara


#### 3.4.1 Genetski algoritam (GA)

Genetski algoritam koristi se za globalno pretraživanje prostora mogućih arhitektura mreže. Svako rješenje predstavlja kombinaciju broja slojeva, broja neurona i logaritamske vrijednosti stope učenja. Fitness funkcija definira se kao negativna validacijska pogreška (MSE) kako bi algoritam maksimizirao točnost. GA je proveden kroz 15 generacija s populacijom od 15 jedinki, a selekcija i mutacija omogućuju istraživanje i iskorištavanje prostora rješenja.

```
def fitness_func(ga_instance, solution, solution_idx):
    n_hidden = int(round(solution[0]))
    neurons = [int(round(n)) for n in solution[1:6]]
    log_lr = solution[6]
    learning_rate = 10 ** log_lr
```

#### 3.4.2 Diferencijalna evolucija (DE)

Diferencijalna evolucija koristi se kao drugi optimizacijski korak, čiji je cilj lokalno poboljšanje rješenja dobivenog iz GA. Funkcija cilja identična je fitness funkciji iz GA, a algoritam se pokreće s istim parametrima pretraživanja. DE je omogućio dodatno smanjenje validacijske pogreške i fino podešavanje arhitekture.



### 3.5 Trening i evaluacija modela


Nakon optimizacije, model se trenira na skupu za treniranje uz korištenje **EarlyStopping** mehanizma kako bi se izbjeglo pretreniranje. Model se potom evaluira na skupu za testiranje koristeći metrike MSE, RMSE i  $R^2$ , koje omogućuju objektivno vrednovanje točnosti modela.

## 4. Rezultati i analiza

Konačni model, dobiven kombinacijom GA i DE, pokazao je visoku točnost predikcije. Na testnom skupu ostvarena je srednja kvadratna pogreška (MSE) od 15.91, korijenska srednja kvadratna pogreška (RMSE) iznosila je 3.99 MW, dok je koeficijent determinacije ( $R^2$ ) iznosio 0.9443.

Vizualna analiza stvarnih i predikcijskih vrijednosti izlazne snage pokazuje jaku linearnu povezanost, pri čemu većina predikcija odstupa manje od  $\pm 5$  MW od stvarne vrijednosti. Ovi rezultati potvrđuju da optimizirani model uspješno generalizira i može se primijeniti u stvarnim operativnim uvjetima.

### Interpretacija slike : Korelacijska matrica značajki (Correlation Heatmap)



Na slici je prikazana korelacijska matrica koja vizualno prikazuje Pearsonove koeficijente korelacije između svih značajki u skupu podataka, uključujući i ciljnu varijablu — izlaznu električnu snagu (PE).

Vrijednosti koeficijenata korelacije kreću se od -1 do +1:

- Vrijednosti bliske +1 označavaju snažnu pozitivnu povezanost (kako jedna varijabla raste, raste i druga),
- Vrijednosti bliske -1 označavaju snažnu negativnu povezanost (kako jedna raste, druga opada),
- Vrijednosti oko 0 ukazuju na slabu ili nepostojeću linearnu povezanost.

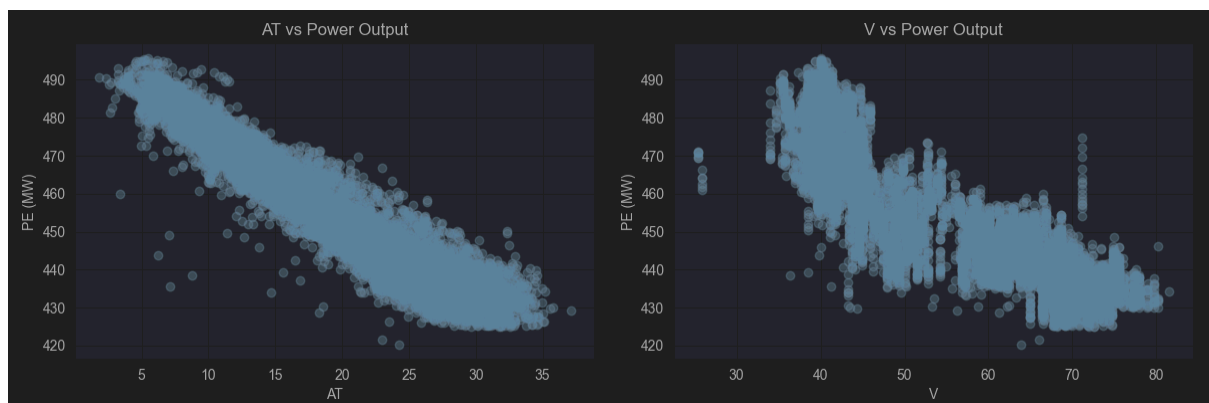
Ključna opažanja:

- Ambijentalna temperatura (AT) ima vrlo snažnu negativnu korelaciju s izlaznom snagom (PE), vrijednosti -0.95, što znači da više temperature značajno smanjuju efikasnost proizvodnje energije.
- Vakuum (V) također pokazuje jaku negativnu korelaciju s PE (-0.87).
- Ambijentalni tlak (AP) ima umjerenu pozitivnu korelaciju s PE (+0.52), dok je povezanost relativne vlažnosti (RH) sa snagom slabija, ali ipak pozitivna (+0.39).

Boje u matrici dodatno naglašavaju ove odnose: nijanse crvene označavaju pozitivnu korelaciju, dok nijanse plave predstavljaju negativnu korelaciju.


### Interpretacija slike : Raspršeni dijagrami značajki u odnosu na izlaznu snagu (PE)

Na slikama su prikazana četiri raspršena dijagrama (scatter plots) koji ilustriraju odnose između svake ulazne značajke i ciljne varijable – izlazne električne snage (PE) izražene u megavatima. Ovi dijagrami omogućuju vizualnu procjenu oblika i jačine međuzavisnosti među varijablama.




**Lijevo – AT vs PE:** Prikazuje snažnu negativnu linearnu povezanost između ambijentalne temperature (AT) i izlazne snage. Kako temperatura raste, izlazna snaga opada, što je u skladu s poznatim fizikalnim svojstvima rada plinske turbine.

**Desno – V vs PE:** Odnos između vakuuma ispušnih plinova (V) i PE također je negativan, no nešto nelinearnijeg karaktera, s izraženim šumom i varijabilnošću u srednjem rasponu.



**Lijevo – AP vs PE:** Ambijentalni tlak (AP) pokazuje blagu pozitivnu povezanost s izlaznom snagom, iako postoji značajan stupanj raspršenosti podataka, što sugerira da AP ima ograničen, ali ne zanemariv utjecaj.

**Desno – RH vs PE:** Relativna vlažnost (RH) ima slabu, ali vidljivu pozitivnu korelaciju s PE, s većom gustoćom podataka pri višim vrijednostima RH i PE.



### Interpretacija slike: Stvarne naspram predikcijskih vrijednosti izlazne snage elektrane

Na slici je prikazan dijagram raspršenja koji uspoređuje stvarne vrijednosti izlazne snage elektrane (PE) na testnom skupu s predikcijama modela temeljenog na optimiziranoj neuronskoj mreži. Svaka točka predstavlja jedan primjer iz testnog skupa, gdje je x-os stvarna vrijednost PE, a y-os predikcija modela.

Crvena isprekidana linija označava idealnu liniju jednakosti ( $y = x$ ), odnosno gdje bi sve predikcije savršeno odgovarale stvarnim vrijednostima. Vizualna blizina točaka toj liniji ukazuje na visoku točnost modela.

Na grafikonu su prikazane i dvije ključne metrike:

- RMSE (Root Mean Squared Error) iznosi 3.99 MW, što znači da model u prosjeku griješi manje od 4 MW.
- $R^2$  koeficijent jednak je 0.9443, što implicira da model objašnjava više od 94% varijance u podacima.

Ovi rezultati potvrđuju visoku prediktivnu snagu razvijenog modela te njegovu prikladnost za primjenu u stvarnim energetske sustavima.

Ova vizualizacija potvrđuje kvantitativne nalaze iz korelacijske matrice i pruža dodatni uvid u nelinearnost i šum prisutan u podacima, što opravdava primjenu neuronskih mreža koje su sposobne modelirati kompleksne odnose među varijablama. Posebice se ističe važnost značajki AT i V kao ključnih prediktora izlazne snage.

## 5. Zaključak

U ovom radu prikazan je učinkovit pristup modeliranju i optimizaciji neuronske mreže za predikciju izlazne snage elektrane. Korištenjem Genetskog algoritma i Diferencijalne evolucije postignuta je visoka točnost, pri čemu je konačni model ostvario **RMSE od 3.99 MW i koeficijent determinacije ( $R^2$ ) od 0.9443** na neviđenim podacima testnog skupa. Ovi rezultati potvrđuju sposobnost modela da precizno predviđa izlaznu snagu na temelju okolišnih uvjeta te opravdavaju njegovu primjenjivost u realnim uvjetima rada elektrana.

Pristup kombinacije GA i DE omogućio je učinkovit odabir hiperparametara modela bez potrebe za ručnim podešavanjem, što dodatno smanjuje vrijeme razvoja i povećava robusnost rješenja. Takav automatizirani okvir može se jednostavno prilagoditi za druge energetske sustave ili probleme tehničke predikcije.

Za buduća istraživanja preporuča se primjena naprednijih arhitektura neuronskih mreža, poput rekurentnih neuronskih mreža (RNN) ili LSTM modela, koji su posebno pogodni za analizu vremenskih serija i predikciju u stvarnom vremenu. Također, integracija SHAP vrijednosti ili drugih metoda interpretabilnosti mogla bi omogućiti dublje razumijevanje utjecaja pojedinih ulaznih značajki na izlaz modela, što bi dodatno povećalo transparentnost i povjerenje krajnjih korisnika.

S obzirom na dobivene rezultate, ovakav model mogao bi se primijeniti u praksi za pametno upravljanje opterećenjem, optimizaciju potrošnje goriva ili predikciju potrebe za održavanjem, čime bi se povećala učinkovitost i smanjili operativni troškovi u energetske sektoru.



## 6. Literatura

1. UCI Machine Learning Repository. *Combined Cycle Power Plant Data Set*. University of California, Irvine. Dostupno na: <https://archive.ics.uci.edu/ml/datasets/combined+cycle+power+plant>
2. Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
3. Mitchell, M. (1998). *An Introduction to Genetic Algorithms*. MIT Press.
4. Storn, R., & Price, K. (1997). *Differential Evolution – A Simple and Efficient Heuristic for Global Optimization over Continuous Spaces*. Journal of Global Optimization, 11(4), 341–359.